


TRUCO-AI

Agentes para el Truco Argentino




Ramiro Martinez, Renzo Dávila
Proyecto Inteligencia Artificial I
Universidad Nacional de Cuyo 2026




¿Por qué el Truco?


- Juego de información imperfecta (no se sabe lo que tiene el rival)
- Combina decisiones secuenciales con apuestas y la mentira como herramienta
- No existe una estrategia óptima universal por la estocasticidad del reparto
- Es un candidato ideal para Reinforcement Learning: recompensas claras, espacio de estados rico, componente psicológico



Objetivos del proyecto

- Entrenar agentes de RL (Q-Learning y PPO) para jugar Truco 1v1
- Compararlos entre sí y contra baselines (Random y Racional)
- Responder: ¿puede RL superar heurísticas manuales en un juego con engaño?





01 Propuesta desarrollada



Entorno de simulación

- Implementación del truco en un entorno de gymnasium.
- Vector de observación de 13 dimensiones (cartas propias, cartas rivales en mesa, puntos, ronda, nivel de truco/envido, etc.).
- 13 acciones posibles con enmascaramiento dinámico.



Los 4 Agentes


Agente	Type	Accuracy
Random		Elige al azar entre acciones válidas
Racional		Heurísticas conservadoras
Q-Learning	RL (Tabular)	Monte Carlo Q-Learning, tabla de valores discretizada
PPO	RL (Red Neuronal)	MaskablePPO con liga de oponentes

Estrategias de entrenamiento




A lo largo de esta etapa, se probaron distintas configuraciones y al final se seleccionaron las que se pensaron más convenientes

- **Q-Learning:** Entrenamiento en su totalidad contra oponente racional
- **PPO:** Liga de oponentes (20% self-play, 60% heurísticos, 20% snapshots)




02

Resultados obtenidos



Matriz de enfrentamientos



Metricas obtenidas (Q-Learning)

Oponente	Win Rate	Puntos prom	Manos jugadas	Manos ganadas	% Mentira Truco	% Mentira Envido
Random	66.1% [63.1, 69.0]	22.75 ± 0.69	6.00 ± 0.30	4.85 ± 0.24	40%	58%
Racional	69.4% [66.5, 72.2]	28.25 ± 0.22	25.91 ± 0.24	13.11 ± 0.15	24%	55%
PPO	21.8% [19.4, 24.5]	18.69 ± 0.49	8.79 ± 0.23	3.56 ± 0.11	48%	56%



¿Que paso con Q-Learning?

- Gana 69.4% vs Racional → aprendió a explotar la predictibilidad
- Solo 66.1% vs Random → la discretización limita su capacidad
- Cae a 21.8% vs PPO → la tabla Q no puede competir con la generalización de una red neuronal
- Cierra partidas en 6 manos vs Random (muy agresivo con envido)
- Pero se extiende a 26 manos vs Racional (desgaste táctico prolongado)



Metricas obtenidas (PPO)

Oponente	Win Rate	Puntos prom	Manos jugadas	Manos ganadas	% Mentira Truco	% Mentira Envido
Random	93.4% [91.7, 94.8]	28.73 ± 0.33	11.21 ± 0.19	9.98 ± 0.18	44%	55%
Racional	76.2% [73.5, 78.7]	25.98 ± 0.52	15.73 ± 0.31	10.17 ± 0.25	37%	58%
Q-Learning	78.2% [75.5, 80.6]	25.61 ± 0.57	8.79 ± 0.23	5.24 ± 0.18	40%	57%







¿Que paso con PPO?




- Domina a todos: 93.4% vs Random, 76.2% vs Racional, 78.2% vs Q-Learning.
- Porcentaje de mentiras similar a Q-Learning, pero con mejoras en win-rate (más efectividad).
- Acumula puntos de forma equilibrada entre truco, envido y abandono del rival.



Fuente de puntos



Mentira en los agentes




- El racional casi no miente, lo que lo hace predecible
- Q-learning hace gran uso de la mentira, debido a su entrenamiento.
- PPO miente selectivamente, lo utiliza como herramienta y no de forma fija.


Distribución de puntos



Points per game: q_learning vs sb3_league




Points per game: random vs sb3_league



03

Conclusiones





Lo que funcionó

- PPO con liga de oponentes es claramente superior a todo lo demás
- RL puede superar heurísticas manuales en juegos de información imperfecta
- La mentira emerge como comportamiento aprendido, no programado





Limitaciones encontradas

- Q-Learning no generaliza contra PPO, debido a la discretización.
- Al momento de entrenar los agentes el self-play puro no es suficiente (tanto en Q-Learning como en PPO).
- CFR (Counterfactual Regret Minimization) se intentó pero fue inviable computacionalmente.



Aprendizajes



- La composición de la liga de oponentes es crítica, por lo que tener más heurísticos nos da una mejor generalización.
- No existe una métrica única para evaluar un agente → hay que mirar win rate + puntos + mentiras + duración + fuentes de puntos en conjunto.
- La mejor forma de evaluar un agente de Truco es jugando contra él.





Posibles mejoras

- Agente adaptativo que clasifique al oponente en tiempo real y cambie de política
- Explorar CFR optimizado con más recursos computacionales



Gracias!

Preguntas?

